

Previsão de Precipitação em Usina Hidrelétrica

Data Analytics - Casa dos Ventos

5 de abril de 2024



Sumário

1 Contexto

2 Objetivo

3 Metodologia

3.1 Coleta dos dados

3.1.1 Usinas Seleccionadas

3.2 Pré-Processamento dos dados

3.3 Treinamento e validação do modelo

3.4 Implementação e uso do modelo

4 Resultados esperados

1 Contexto

A geração de energia hidrelétrica é fundamental para o Brasil, respondendo por mais de 60% da matriz energética nacional. A precipitação de chuva é um fator crucial na determinação da vazão dos rios e, consequentemente, na geração de energia.

2 Objetivo

Desenvolver um modelo de machine learning ou séries temporais para realizar previsões meteorológicas de precipitação de chuva em uma usina hidrelétrica específica, com horizonte de 15 dias. O modelo poderá ser treinado com histórico de previsões do ECMWF, [GEFS](#) e do [CFS](#) e de precipitação real na região da usina.

3 Metodologia:

3.1 dados de previsão meteorológicas

Previsões meteorológicas do ECMWF, GEFS (Global Ensemble Forecast System) e do CFS para os últimos 2 anos, com por usina.

Precipitação real na região da usina hidrelétrica pelo merge.

- ECMWF - Set-2022 ate agora
 - Mudança de modelo junho de 2023
- GEFS - set 2022 até agora
 - Preencher dias faltantes (~30)
 - Verificar possibilidade de coleta de dados mais antigos
- CFS - 45 dias - ver históricos
 - outubro de 2022

3.1.1 Usinas selecionadas

Grande: Furnas - PSATFUR

Paranaíba: Emborcação - PSATEMB ou Itumbiara - PSATIMBR

Paraná: Itaipu - PSATITP

Iguaçu: Foz do Areia (ou G. B. Munhoz) - PSATFZA

Uruguai: Campos Novos - PSATCNV

Tocantins: Lajeado - PSATLAJ

Madeira: Jirau - PSATJIRA

Xingu: Pimental - PSATPIME

3.2 Pré-processamento dos dados:

Limpeza e tratamento de dados inconsistentes ou ausentes.

Normalização dos dados para melhorar a performance do modelo.

Seleção de features relevantes para a previsão de precipitação.

3.3 Treinamento e validação do modelo:

Treinamento de diferentes modelos de machine learning (regressão linear, Random Forest, Boosting Trees, redes neurais), ou outros métodos como os séries temporais (ARIMA, SARIMA) utilizando os dados coletados.

Avaliação da performance dos modelos através de métricas como RMSE (Root Mean Square Error) e R^2 (coeficiente de determinação).

Seleção do modelo com melhor performance para a previsão de precipitação na usina hidrelétrica.

3.4 Implementação e uso do modelo:

Implementação do modelo em um ambiente que possa ser colocado em produção, utilizando Python ou R.

Geração de previsões de precipitação de chuva para os próximos 15 dias, com atualização diária.

4 Resultados esperados:

Aumento da precisão das previsões de precipitação de chuva na usina hidrelétrica. Ter uma visão independente de vazão e consequentemente de preço de energia.